



HW

一. 问答题

1. 什么是 robots.txt 文件？它在爬虫开发中起到什么作用？

答：

robots.txt 是网站放置在根目录的一个文本文件，用于告知网络爬虫哪些页面或目录允许访问，哪些不允许访问。它是一种“君子协定”，并不能从技术上彻底阻止爬虫访问，但遵守它有助于避免法律风险或被封禁 IP。

2. 简述一个典型爬虫的基本工作流程。

答：

典型爬虫工作流程包括：

- 发起 HTTP 请求（设置请求头、方法、参数等）；
- 接收服务器响应（读取状态码、响应头和响应体）；
- 解析内容（HTML/JSON/XML 等）；
- 提取所需数据（CSS 选择器、XPath、正则等）；
- 存储数据（文件或数据库）；
- 发现新链接并加入待爬取队列（去重处理）。

3. 在反反爬策略中，为什么需要轮换 User-Agent 和使用代理池？

答：

- **轮换 User-Agent**：通过模拟不同浏览器和设备的访问，降低被识别为爬虫的概率。
- **使用代理池**：避免单个 IP 过于频繁访问而被封禁，代理池可在 IP 被封时切换新的可用 IP，提高爬虫的稳定性和持续性。

二. 编程题

编写一个 Python 爬虫，抓取《肖申克的救赎》电影的前 5 页短评内容，并保存到本地 CSV 文件。

要求：

- 使用 `requests` 获取网页 HTML；
- 使用 `BeautifulSoup` 解析 HTML 并提取评论内容；

- 循环爬取前 5 页（每页 20 条评论）；
- 将评论保存到 `comments.csv` 文件，每行一个评论；
- 每次请求之间暂停 1~2 秒，防止被封。

提示：

- 《肖申克的救赎》豆瓣评论页 URL：
<https://movie.douban.com/subject/1292052/comments?start=0&limit=20>
- 页码控制： `start` 参数依次为 `0, 20, 40, 60, 80`。
- 评论内容在 `<span class="short">` 标签内。