



HW

一. 问答题

1. 什么是 robots.txt 文件？它在爬虫开发中起到什么作用？
2. 简述一个典型爬虫的基本工作流程。
3. 在反反爬策略中，为什么需要轮换 User-Agent 和使用代理池？

二. 编程题

编写一个 Python 爬虫，抓取《肖申克的救赎》电影的前 5 页短评内容，并保存到本地 CSV 文件。

要求：

- 使用 `requests` 获取网页 HTML；
- 使用 `BeautifulSoup` 解析 HTML 并提取评论内容；
- 循环爬取前 5 页（每页 20 条评论）；
- 将评论保存到 `comments.csv` 文件，每行一个评论；
- 每次请求之间暂停 1~2 秒，防止被封。

提示：

- 《肖申克的救赎》豆瓣评论页 URL：
<https://movie.douban.com/subject/1292052/comments?start=0&limit=20>
- 页码控制：`start` 参数依次为 0, 20, 40, 60, 80。
- 评论内容在 `<span class="short">` 标签内。